

OpenClaw 系统性评测方案（修订版）

一、核心评测目标

- 1、验证网关基础功能、插件 / Skill 全生态、多 Agent 并行协作的完整性、正确性与兼容性；
- 2、验证多梯度并发、高频心跳风暴、海量混合消息场景下服务承载能力、内存 / CPU 负载合理性、Token 资源可控性；
- 3、验证 72 小时长期连续运行、进程强制重启、网络闪断、版本升降级回滚后的服务稳定性、故障自愈与资源回收能力；
- 4、覆盖真实业务用户场景（搜索 / 编码 / 长文本 / 多轮对话 / 多插件链式任务），输出标准化用例、自动化巡检 / 压测脚本、执行手册、多维度评测报告、发布门禁规则，形成可长期复用的全套评测资产；
- 5、补充专项验证：无内存泄漏、无 OOM 风险、无日志风暴、无无限重试风暴、无 Token 异常飙升。

二、评测整体范围

- 1、基础功能 & 插件生态 & 真实业务场景兼容性测试（新增真实用户场景、Token 基线采集、WebSocket 双向协议校验专项）
- 2、多梯度并发压力 & 混合业务场景压测（核心重点，含心跳风暴、高频消息、多会话并发）
- 3、长期稳定性 & 异常故障 & 版本升降级兼容测试（含进程 kill、网络阻断、多 Agent 故障隔离、72h 长稳）

三、第一部分 基础功能 & 生态兼容性 & 真实业务场景测试

1. 测试目的

验证网关启停 / 配置 / WebSocket 基础功能可用；插件全流程加载、调用、多版本共存、升级无退化；覆盖搜索、编码、长文本、多轮对话等真实业务任务，采集标准化 Token 消耗基线；配置变更永久生效，无资源泄漏、无功能退化。

2. 测试用例 & 执行标准

（1）网关核心基础功能

1) 服务启停与状态检查

重复执行 start/stop/restart, 包含端口占用、进程锁冲突异常场景;

观测进程 PID、目标端口监听状态、systemd 托管服务状态、启动 / 停止日志;

验收: stop/restart 可正常托管进程, 端口占用场景有明确报错提示, 无僵尸进程。

2) WebSocket 双向通信专项测试

客户端机器通过 ws:// 网关内网 IP: 目标端口建立长连接 (wscat/Python 双客户端验证);

分两步验证: ①单向下行消息收发稳定性 ②握手 challenge 应答双向闭环校验;

验收: 单向消息无乱码、无丢包、无自动断连; 双向握手协议校验逻辑正常, 不会返回 1008 策略违规强制断连。

3) 网关配置变更持久化测试

修改监听端口、心跳配置、最大连接限制, 区分 systemd 自动固化 / 前台 run 两种启动方式;

修改 JSON 配置文件后重启服务, 核验配置永久生效;

验收: 配置修改重启后参数生效, 无端口固化覆盖问题; 支持心跳间隔自定义配置。

(2) Skill / 插件生态全量测试

1) 插件批量加载

批量安装编码、加密、日程、文件处理等多品类热门插件, 含同功能多版本并行安装;

验收: 文件无磁盘冲突, 全部插件可正常落地, 无安装 404 阻塞本地环境。

2) 插件单调用、链式组合调用

单技能独立执行、多插件串联链式任务, 使用原生 CLI / 脚本两种方式调用;

验收: 任务执行结果精准, 无进程卡死、闪退; 多插件混用无资源抢占冲突。

3) 插件版本兼容与重复安装验证

多版本共存、--force 强制覆盖升级、连续多次重装;

验收: 升级后原有插件配置不丢失, 无兼容性退化; 多次重装无冗余垃圾文件、无内存泄漏; 客户端 list/info 可正常检索全部已安装插件。

4) 异常插件容错测试

访问 ClawHub 不存在 / 缺失依赖的破损插件;

验收：安装流程自动终止，不污染本地插件目录，基础拦截容错逻辑完备。

5) 插件启停控制（新增）

验证 enable/disable 子命令可在线开关插件，无需重启网关。

(3) 真实业务场景 + Token 消耗基线测试

覆盖线上标准用户任务：联网搜索、代码编码、长文本总结、多轮上下文对话、运维脚本、加密编码、并发多会话、无效异常请求；

- 1) 单用户基线任务：采集输入 Token、输出 Token、总 Token、单次任务耗时；
- 2) 多轮上下文对话：验证历史记忆携带机制，Token 累积逻辑平稳；
- 3) 异常请求容错：乱码、无效提问、错误插件指令；

验收：

正常任务 Token 随复杂度线性递增，无无效推理损耗；

超长文本无溢出、截断浪费；异常请求极低 Token 消耗；

无死循环调用、无心跳 Token 异常飙升，所有基线数据可归档用于版本对比。

3. 观测指标

进程存活状态、端口监听状态、接口响应时延、全量日志 error/panic/fatal 错误条数、单任务完成耗时、输入 / 输出 / 总 Token、磁盘占用、内存占用、插件检索展示可用性。

四、第二部分 并发压力 & 混合业务场景压测

1. 测试目的

模拟多用户在线并发、高频心跳风暴、海量批量消息、多插件混合业务场景，探测版本稳定并发承载上限；验证 CPU / 内存负载可控、连接稳定、无日志 / 重试风暴、无内存泄漏。

2. 压测梯度

档位	并发连接数	场景说明	单轮持续时长
低并发	200	日常在线，常规心跳 + 普通单消息业务	1h

档位	并发连接数	场景说明	单轮持续时长
中并发	500	中度负载，常规心跳 + 批量插件调用任务	1h
高并发	1000	业务流量高峰，密集消息收发 + 多插件链式任务	1h
极限并发	1500/2000	压力边界极限探测，心跳风暴叠加高频消息	1h

3. 细分压测用例

(1) 长连接并发压测

多客户端常驻 WebSocket 长连接，持续推送普通业务消息；

验收：连接建立成功率 $\geq 99\%$ ，无批量无故断连，进程无崩溃。

(2) 心跳风暴专项压测

缩短心跳推送间隔，模拟海量客户端高频心跳上报；

验收：CPU 负载平稳可控，无日志刷屏风暴、无无限重试队列堆积、网关持续可用。

(3) 高频批量消息压测

并发连接持续批量推送业务消息；

验收：消息丢包率 = 0，无消息队列持续堆积，单条消息处理时延平稳无持续抬升。

(4) 真实混合业务压测

并发长连接同时执行插件调用、消息收发、多轮对话，还原线上混合负载；

验收：插件调度不阻塞网关主服务，整机 CPU / 内存无持续上涨泄漏。

4. 补充规则

1、任意档位出现持续卡顿、批量断连、内存持续上涨则停止升档，记录当前版本稳定并发上限；

2、每一轮压测全程采集系统资源、网关日志、连接数据，完整归档用于复盘。

五、第三部分 长期稳定性 & 异常故障 & 版本升降级 & 多 Agent 测试

1. 测试目的

验证 72 小时不间断长期运行可靠性；进程崩溃、网络闪断故障自愈能力；版本升级 / 降级 / 回滚无性能回退；多 Agent 并行隔离、单实例故障无连锁崩溃。

2. 测试用例

(1) 72 小时长期稳定性测试

操作：维持 500 中并发长连接后台挂机 72h，定时循环执行插件任务、收发业务消息、心跳上报；每 2 小时自动执行资源巡检脚本采集指标。

观测项：CPU、内存、TCP 连接数、进程重启次数、主动 / 被动断连次数、日志致命错误条数、Token 消耗增长趋势。

验收：72h 全程无宕机、无异常自动重启、无批量断连；内存无持续爬升泄漏，功能全程可用。

(2) 服务异常强制重启压测中执行

压测负载下执行 kill -9 强制销毁网关进程，观测 systemd 自拉起逻辑；

验收：服务 3s 内快速拉起，原有配置完整保留，客户端可自动重连恢复会话。

(3) 网络闪断恢复测试

iptables 临时阻断网关端口，静置后删除规则恢复连通；

验收：客户端自动重连，历史会话上下文无错乱、数据无丢失。

(4) 版本升降级、反复回滚全流程测试

多次执行升级、降级、版本回滚循环；

验收：版本切换流程顺畅，切换后功能、性能无回退，插件 / 网关配置完整保留，无资源异常堆积。

(5) 多 Agent 并行协作与故障隔离专项

启动 3 个及以上独立 Agent 实例，并行执行业务任务；手动终止单实例验证隔离性；

验收：多实例通信正常、资源互不抢占；单 Agent 故障退出不扩散，其余实例持续正常处理任务，无全局服务中断。

六、监控、日志 & 自动化评测资产

1. 全维度数据采集指标

- 1) 系统资源层：CPU 使用率、内存占用、Swap 占用、磁盘空间、TCP 总连接数、网络 IO；
- 2) 应用网关层：panic/fatal 致命日志条数、普通 error/warn 计数、长连接在线数、消息丢包率、业务任务完成率；
- 3) 业务指标层：单任务耗时、输入 / 输出 / 总 Token、插件执行成功率。

2. 自动化脚本资产清单

- 1) WebSocket 多梯度并发压测脚本 (Node.js)；
- 2) 系统 & 网关资源定时巡检 Shell 脚本 claw_monitor.sh (每 2 小时自动采集)；
- 3) 一键网关启停 / 清理脚本、72h 测试收尾备份清理脚本；
- 4) Python 脚本：模拟客户端 WebSocket 连接、批量调用插件、采集 Token 基线数据。

3. 日志标准化管理

- 1) 网关日志使用 shell 重定向落地，支持长期归档；
- 2) 按测试阶段分目录存储日志，自动统计 panic、fatal、error 等异常关键字条数。

七、交付物完整清单

- 1、标准化测试用例库 (功能 / 插件生态 / Token 基线 / 并发压测 / 长期稳定性 / 异常故障 / 多 Agent 分类)
- 2、多份独立评测报告：功能 & 插件生态测试报告、真实业务 Token 基线报告、并发梯度压测报告、72h 长期稳定性报告、多 Agent 故障隔离专项报告
- 3、可复制落地执行文档：环境部署手册、网关配置修改操作手册、版本升降级回滚操作手册、全套测试执行操作手册
- 4、全套自动化测试脚本、巡检脚本、清理脚本资产
- 5、标准化版本发布门禁验收规则

八、版本发布门禁规则

- 1、功能门禁：网关核心功能、全品类热门插件执行通过率 100%；无 panic/fatal 致命 BUG；WebSocket 双向握手通信功能正常；插件 list/info 检索无展示缺陷。
- 2、并发门禁：500 中并发场景下长连接成功率 $\geq 99\%$ ，业务消息丢包率 = 0；心跳风暴场景无日志风暴、无限重试队列。

- 3、资源门禁：2GB 内存环境常态运行内存 $\leq 1.2\text{GB}$ ，峰值瞬时内存 $\leq 1.6\text{GB}$ ；常态 CPU 使用率 $\leq 70\%$ ；各类负载结束后内存可自动回落至基线，无持续泄漏。
- 4、长期稳定门禁：72h 连续挂机运行无宕机、无异常自动重启、无批量长连接断连；内存无缓慢持续上涨。
- 5、版本兼容门禁：版本升级 / 降级 / 回滚流程正常，切换后无性能回退、插件 / 网关配置完整保留；无资源堆积异常。
- 6、Token 资源门禁：全场景无死循环调用、无心跳 Token 异常飙升；异常请求仅消耗极低 Token，无无效推理资源浪费。
- 7、故障隔离门禁：多 Agent 单实例故障无连锁崩溃，剩余实例持续对外提供服务；进程 kill、网络闪断场景自愈恢复正常。